

Parcial 2 Sistema RAG FinTech

Proyecto de Retrieval-Augmented Generation
Parcial 2 | Inteligencia Artificial Aplicada

Economía

Integrantes

Verónica Marín Bahamon

Alejandro Montaña

María Isabella Pareja

27 de mayo de 2026

1. Introducción

Contexto del Problema:

El ecosistema de tecnología financiera (FinTech) en Colombia ha experimentado un crecimiento acelerado en la última década, impulsado por la necesidad de inclusión financiera, la digitalización de pagos y el surgimiento de nuevos modelos de negocio (como las SEDPEs, plataformas de financiamiento colaborativo y neobancos). Sin embargo, este dinamismo ha estado acompañado de un marco regulatorio denso, complejo y en constante evolución emitido por entidades como la Superintendencia Financiera de Colombia (SFC), el Ministerio de Hacienda y la Unidad de Proyección Normativa y Estudios de Regulación Financiera (URF).

Para los economistas, asesores legales y tomadores de decisiones en el sector FinTech, la consulta de esta normativa representa un proceso extenso, ya que estos documentos regulatorios suelen ser largos, redactados en un lenguaje técnico-jurídico muy específico y distribuidos en múltiples archivos PDF no estructurados. Extraer respuestas precisas y oportunas sobre requisitos de capital, límites de captación o condiciones de exclusión regulatorias consume recursos valiosos y está sujeto a errores de interpretación humana.

Justificación de la Solución: ¿Por qué RAG?

Frente a este problema de asimetría de información y altos costos de búsqueda, se evaluaron tres enfoques de Inteligencia Artificial para el procesamiento de lenguaje natural:

Prompting directo, Fine-Tuning y RAG.

Primero, el prompting directo, que consiste en hacerle preguntas directamente a un Modelo de Lenguaje Grande (LLM) comercial sin suministrarle los documentos, presenta ciertas limitaciones como las alucinaciones, y es que los LLM están diseñados para generar texto probabilísticamente coherente, no necesariamente factual. Ante vacíos de información sobre leyes específicas colombianas, el modelo tiende a inventar decretos o normativas. También, para estos modelos, no es viable copiar y pegar miles de páginas de PDFs en cada interacción debido al costo de tokens y a la pérdida de atención del modelo en textos excesivamente largos. Finalmente para este caso, el modelo podría ignorar reformas recientes, proporcionando así información desactualizada.

Segundo, el Fine tuning (que consiste en tomar un modelo ya entrenado de forma general y reentrenarlo con un conjunto de datos más pequeño y específico) no es el más apropiado para este caso porque puede implicar un alto costo computacional, ya que puede requerir infraestructura de hardware costosa (GPUs de alta gama) y un proceso intensivo de preparación de datos etiquetados. Así mismo, al ser entrenado con un conjunto de datos más pequeño y particular, si la Superintendencia Financiera emite una nueva circular mañana, el modelo queda desactualizado inmediatamente y requiere un costoso reentrenamiento. Finalmente, los LLM siguen teniendo dificultades para recordar datos

numéricos exactos, fechas o artículos específicos a través de sus parámetros, manteniendo un alto riesgo de alucinación.

Teniendo en cuenta esto, el RAG es el enfoque seleccionado para este proyecto, ya que RAG separa el conocimiento del modelo de la base de datos documental (memoria no paramétrica). Nos pareció el más adecuado dado que al estar obligado por un prompt del sistema a responder *únicamente* con la información que se le recupera en tiempo real desde los documentos indexados en el índice vectorial FAISS, se reduce las alucinaciones considerablemente. Además tenemos un factor de bajo costo de actualizar los datos, y es que si la regulación cambia, no es necesario reentrenar el modelo. Simplemente se actualiza el archivo en el repositorio de GitHub y el sistema indexa los nuevos vectores de manera instantánea a un costo computacional despreciable. Finalmente, el componente más útil por así decirlo del RAG es que permite tener una trazabilidad de lo que se está investigando, y es que al realizar la consulta, el sistema devuelve la respuesta acompañada de la fuente y el fragmento del PDF original de donde se extrajo la información, permitiendo una verificación legal de la información por parte de una persona.

Objetivo del Sistema

El objetivo de este sistema es diseñar, implementar y evaluar un pipeline RAG funcional y eficiente que permita a economistas y reguladores realizar consultas en un lenguaje natural sobre el ecosistema FinTech en Colombia. El sistema debe garantizar respuestas precisas en español, eliminar alucinaciones mediante restricciones estrictas de contexto y mostrar un análisis cualitativo de su desempeño. La finalidad última del sistema consiste en mitigar las fricciones de búsqueda y la asimetría de información imperante en el ecosistema regulatorio latinoamericano. Al centralizar y contextualizar la normativa nacional, se previene la contaminación cruzada de conceptos provenientes de jurisdicciones extranjeras, facilitando una toma de decisiones eficiente y robusta para los actores del mercado.

2. Dataset y Documentos

Fuentes Utilizadas

Para alimentar la base de conocimiento vectorial de nuestro RAG, primero se buscaron documentos que fueran valiosos para nuestro proyecto, que nos dieran información valiosa para responder a las preguntas relacionadas con temas de fintech. Luego, se creó un repositorio de GitHub del proyecto llamado `parcial2-rag-fintech` donde dentro de este en una carpeta llamada `(/datap2)` se guardaron las fuentes. Las fuentes de información provienen de los canales oficiales del gobierno y la industria en Colombia:

- Superintendencia Financiera de Colombia (SFC): Circulares normativas, decretos de creación del Espacio Controlado de Prueba (Sandbox regulatorio) y guías conceptuales para la constitución de entidades financieras de base tecnológica.

- Congreso de la República de Colombia: Leyes de protección de datos personales aplicables a canales digitales y regulaciones sobre comercio electrónico y firmas digitales.
- Asociación Colombia FinTech: Reportes conceptuales y de caracterización del marco legal vigentes para startups financieras en el país.

Descripción de los Documentos dentro de github

El conjunto de datos de prueba está compuesto por los siguientes documentos clave de la regulación financiera nacional:

1. 20230928Latamfintechmarket.pdf

- **Entidad:** Superintendencia Financiera de Colombia (SFC).
- **De qué se trata:** Es una presentación del Superintendente César Ferrari sobre el **ecosistema fintech en Colombia**. Analiza la situación actual, los avances en el marco regulatorio (como la Arenera y licencias ágiles) y la estrategia institucional para masificar la innovación financiera.

2. 20250529rif2024.pdf

- **Entidad:** Superintendencia Financiera de Colombia (SFC) y Banca de las Oportunidades.
- **De qué se trata:** Es el **Reporte de Inclusión Financiera (RIF) 2024**. Proporciona un análisis estadístico profundo sobre el acceso y uso de productos de depósito, crédito y seguros en Colombia, destacando la digitalización y las brechas persistentes en zonas rurales.

3. 23VerificacionrequisitosingresoECP.pdf

- **Entidad:** Superintendencia Financiera de Colombia (SFC).
- **De qué se trata:** Es una **lista de chequeo** para la verificación de requisitos para el **ingreso al Espacio Controlado de Prueba (ECP)** o sandbox regulatorio. Detalla los documentos necesarios según el tipo de solicitante para probar desarrollos tecnológicos innovadores.

4. 24constEntVigECP.pdf

- **Entidad:** Superintendencia Financiera de Colombia (SFC).
- **De qué se trata:** Se trata de una **lista de chequeo** específica para el trámite de **constitución de entidades vigiladas** dentro del ECP y la expedición del Certificado de Operación Temporal (COT), enfocándose en la estructura de propiedad y planes de negocio.

5. Decreto_1234_de_2020.pdf

- **Entidad:** Gobierno Nacional (Presidencia de la República).
- **De qué se trata:** Decreto que reglamenta el **espacio controlado de prueba (sandbox)** para actividades de innovación financiera. Define los términos, requisitos de ingreso, el funcionamiento de las pruebas temporales y los mecanismos de salida o transición a licencias permanentes.

6. Decreto_1357_de_2018.pdf

- **Entidad:** Gobierno Nacional (Presidencia de la República).
- **De qué se trata:** Decreto que regula la **actividad de financiación colaborativa (crowdfunding)** a través de la emisión de valores. Establece las reglas para las sociedades de financiación colaborativa, los límites de financiación y los requisitos para aportantes y receptores.

7. GuiaEntidadesDigitales.pdf

- **Entidad:** Superintendencia Financiera de Colombia (SFC).
- **De qué se trata:** Es una **guía externa para la supervisión de entidades con enfoque digital** (Fintech o en transformación digital). Complementa el Marco Integral de Supervisión (MIS) con criterios específicos sobre modelos de negocio digitales, riesgos de ciberseguridad y gobierno corporativo.

8. Ley_2069_de_2020.pdf

- **Entidad:** Congreso de la República de Colombia.
- **De qué se trata:** Conocida como la **Ley de Emprendimiento**, establece un marco para propiciar el crecimiento y sostenibilidad de las empresas. Incluye medidas sobre tarifas diferenciadas, acceso a compras públicas para MiPymes y promoción de microseguros.

9. Ley_2155_de_2021.pdf

- **Entidad:** Congreso de la República de Colombia.
- **De qué se trata:** La **Ley de Inversión Social**. Contiene medidas de política fiscal y lucha contra la evasión. En el contexto financiero, es relevante por regular el sistema de **factura electrónica (RADIAN)** como título valor para facilitar la financiación empresarial.

10. Manual del Espacio Controlado de Prueba.pdf

- **Entidad:** Superintendencia Financiera de Colombia (SFC).
- **De qué se trata:** Es un **manual instructivo** que explica el propósito, los criterios de evaluación (capital, idoneidad, riesgos) y el proceso paso a paso para que los interesados puedan ingresar y operar en el ECP.

11. P1 Tit I Cap VIII- Espacio Controlado de Prueba.pdf

- **Entidad:** Superintendencia Financiera de Colombia (SFC).
- **De qué se trata:** Corresponde a la **Circular Externa 016 de 2021**. Incorpora instrucciones generales a la Circular Básica Jurídica sobre el ECP, estableciendo requisitos formales de aplicación, deberes de información publicitaria y protección al consumidor.

Justificación de la Selección

La elección de estos documentos se realizó ya que estos contribuyen a una alta sensibilidad al detalle normativa, dado que el éxito en el diseño de un producto FinTech depende en gran parte de no violar umbrales específicos de captación de las SEDPEs o parámetros exactos de autenticación de identidad. El RAG permite capturar estos detalles exactos donde un modelo genérico fallaría por imprecisión. En el ámbito normativo, las leyes y circulares no operan en

el vacío. Por ejemplo, si un economista o abogado quiere entender cómo ingresar al Sandbox Regulatorio, no puede limitarse a leer un solo archivo. Necesita cruzar el Decreto 1234 (que define las reglas generales del Gobierno) con la Circular Externa de la SFC (que dicta el manual y las listas de chequeo operativas). Ahora, nuestro sistema RAG soluciona este desafío de la siguiente manera. Primero, hace una búsqueda por significado (Similitud semántica): En lugar de buscar palabras exactas (como haría un buscador convencional de PDF), el sistema entiende el *concepto* de la consulta del usuario. Luego, el algoritmo extrae exactamente los 5 fragmentos de texto (\$K=5\$) con mayor relevancia semántica. Lo potente es que no se restringe a un solo PDF; puede traer simultáneamente 2 fragmentos del Decreto Presidencial y 3 fragmentos de la Circular Operativa. Al procesar estos 5 fragmentos concurrentemente, el LLM recibe en su ventana de contexto información de distintas fuentes oficiales. Esto le permite redactar una respuesta unificada y coherente que cruza de manera automática el marco de ley general con la regulación procedimental específica, ahorrándole al usuario horas de lectura cruzada manual. Al utilizar este conjunto acotado y verificado de documentos oficiales, evitamos que el generador tome información desactualizada de blogs o foros de internet, garantizando que el usuario del RAG siempre recibe respuestas basadas en el estado del arte de la legislación colombiana.

3. Arquitectura del Sistema

Visión general del pipeline

El sistema implementado sigue la arquitectura de *Retrieval-Augmented Generation* (RAG), compuesta por dos fases principales que operan de forma secuencial: una fase offline de indexación, que se ejecuta una sola vez para preparar la base de conocimiento, y una fase online de consulta, que se activa cada vez que un usuario hace una pregunta.

El flujo del sistema es el siguiente: primero se procesan los documentos normativos, son fragmentados y convertidos en representaciones vectoriales que se almacenan en un índice. Luego, cuando se hace una consulta, se convierte en el mismo espacio vectorial, se recuperan los fragmentos más relevantes por similitud geométrica, y esa información se entrega como contexto a un modelo de lenguaje que genera la respuesta final en lenguaje natural.

Ingesta y extracción de documentos

La recolección de documentos se hizo sobre el cuerpo normativo colombiano relevante para los casos de FinTech y crowdfunding. Se trabajó con 12 documentos PDF, de los cuales 11 fueron procesables exitosamente con extracción de texto directa.

Para la extracción de texto se utilizó la librería pdfplumber, preferida sobre pypdf porque ofrece mejor soporte para PDFs con estructuras complejas como tablas de doble columna y

formatos de publicación oficial, comunes en decretos y circulares de la Superintendencia Financiera de Colombia. La función de extracción recorre el PDF página a página, descarta páginas con menos de 30 caracteres (páginas de imágenes o portadas en blanco), y concatena el contenido textual con separadores de doble salto de línea para preservar la estructura de párrafos.

El documento `ce015_25.pdf` arrojó cero páginas extraídas, esto porque es un PDF de contenido escaneado sin capa de texto seleccionable. Este archivo fue omitido del proceso por su dificultad para procesarlo como texto.

Fragmentación del texto (*Chunking*)


Una vez extraído el texto, cada documento se fragmentó en unidades más pequeñas usando `RecursiveCharacterTextSplitter` de `LangChain`. Los parámetros elegidos fueron:

Parámetro	Valor	Justificación
<code>chunk_size</code>	800 caracteres	Captura aproximadamente un artículo regulatorio completo sin exceder la capacidad del encoder
<code>chunk_overlap</code>	150 caracteres (18%)	Evita cortar conceptos clave o referencias normativas entre fragmentos consecutivos
<code>separators</code>	<code>\n\n, \n, . ,</code>	Respetar la jerarquía natural del documento: párrafos → líneas → oraciones

La estrategia `RecursiveCharacterTextSplitter` intenta dividir por el separador más grueso disponible y solo separa por el siguiente nivel si el fragmento supera el tamaño máximo. Esto preserva mejor la coherencia semántica que una división fija por número de caracteres.

El proceso generó un total de 1.540 fragmentos a partir de los 11 documentos que se pudieron procesar. Las estadísticas descriptivas de los fragmentos muestran una media de 678 caracteres por chunk con una desviación estándar de 153, un mínimo de 38 caracteres y un máximo de 800 caracteres, que es el límite escogido. La mediana (737 caracteres) cercana al máximo indica que la mayoría de los chunks aprovechan bien la capacidad configurada.

Al escoger el tamaño de los fragmentos, se tiene que tener en cuenta el siguiente trade-off: fragmentos demasiado grandes (>2.000 caracteres) producen embeddings que promedian demasiados conceptos distintos, lo que hace que la búsqueda sea imprecisa; fragmentos demasiado pequeños (<200 caracteres) entregan un contexto insuficiente al modelo para producir respuestas completas. El valor de 800 caracteres representa un equilibrio entre estos dos casos para textos legales densos.



Aquí podemos ver que el documento que tuvo más chunks fue 20250529rif2024, lo cual tiene sentido ya que es el archivo con más páginas (270). También vemos que la distribución presenta una marcada asimetría hacia la izquierda (sesgo negativo). La inmensa mayoría de los fragmentos se concentran densamente en el rango de 650 a 800 caracteres, registrando el pico más alto de frecuencia (más de 350 chunks) inmediatamente antes de la línea punteada roja.

Modelo de embeddings (encoder)

Modelo seleccionado: intfloat/multilingual-e5-small

Este modelo es un encoder de tipo transformer bidireccional, entrenado específicamente para recuperar información en múltiples idiomas. A diferencia de los modelos generativos, los encoders procesan la secuencia completa de entrada en paralelo y producen una representación vectorial densa de ella, sin generar texto nuevo.

Se eligió multilingual-e5-small por dos razones principales. Primero, al ser la variante small, su ejecución en CPU dentro de Google Colab es viable sin necesidad de GPU dedicada ni pagar por procesamiento. Segundo, el modelo E5 (EmbEddings from bidirEctional Encoder rEpresentations) fue diseñado específicamente para tareas de búsqueda semántica, a diferencia de modelos de embedding genéricos.

Una característica importante de los modelos tipo E5 es que requiere prefijos especiales en el texto de entrada para funcionar correctamente: los fragmentos del cuerpo se preprocesan con

el prefijo "passage: ", mientras que los queries del usuario se procesan con el prefijo "query: ". Esta distinción permite al modelo diferenciar entre el rol de cada texto en la búsqueda.

El modelo produce vectores de 384 dimensiones con normalización L2 activada (`normalize_embeddings=True`), lo que garantiza que todos los vectores tengan norma unitaria y hace que el producto punto entre dos vectores sea equivalente a la similitud coseno entre ellos.

Base de datos vectorial (FAISS)

Los 1.540 embeddings generados se indexaron en FAISS (*Facebook AI Similarity Search*), una librería desarrollada por Meta para búsqueda eficiente por similitud en espacios de alta dimensionalidad.

A diferencia de una base de datos relacional, que organiza información en filas y columnas y opera con comparaciones exactas, FAISS organiza los vectores en estructuras geométricas que permiten encontrar los k vecinos más cercanos a un vector de consulta sin compararlo exhaustivamente con todos los vectores del índice. Para el tamaño de este cuerpo que tiene 1.540 vectores de 384 dimensiones, se utilizó un índice plano (`IndexFlatL2`), que sí realiza búsqueda exacta por distancia euclidiana, garantizando precisión máxima a un costo computacional aceptable dado el volumen.

La similitud entre dos vectores se mide mediante similitud coseno, que calcula el ángulo entre los vectores en el espacio de 384 dimensiones. Dos fragmentos son semánticamente similares cuando su representación vectorial apunta en la misma dirección geométrica, independientemente de la magnitud de cada vector. Dado que los embeddings están normalizados, la similitud coseno es equivalente al producto punto, que FAISS calcula de forma muy eficiente.

El índice fue persistido en disco bajo la carpeta `faiss_index_fintech_multilingual/`, lo que permite cargarlo en sesiones posteriores sin necesidad de recalcular los embeddings.

Modelo generador (decoder)

Modelo seleccionado: llama-3.1-8b-instant vía API de Groq

Nota importante: Para ejecutar el pipeline descrito en este documento es necesario configurar dos credenciales externas. La API key de Groq, requerida para acceder al modelo LLaMA 3.1, se obtiene de forma gratuita creando una cuenta en console.groq.com. La token de Hugging Face, requerida para descargar el modelo de embeddings `intfloat/multilingual-e5-small`, se obtiene igualmente sin costo en huggingface.co/settings/tokens. En Google Colab, ambas credenciales deben registrarse en la sección Secrets del entorno (ícono de llave en el panel izquierdo) bajo los nombres `GROQ_API_KEY` y `HF_TOKEN` respectivamente, sin necesidad de escribirlas directamente en el código.

El generador es el componente responsable de sintetizar la respuesta en lenguaje natural a partir de la pregunta del usuario y los fragmentos recuperados. A diferencia del encoder, que produce un vector a partir de texto, este es un decoder de tipo transformer autoregresivo: genera el texto de salida token por token, condicionado en el prompt completo.

Se eligió LLaMA 3.1 sobre la alternativa inicial (FLAN-T5-Large) por razones técnicas concretas. FLAN-T5-Large tiene una ventana de contexto de solo 512 tokens, que resulta insuficiente cuando el prompt combina 5 fragmentos de contexto en español más las instrucciones del sistema. LLaMA 3.1 en cambio soporta hasta 128.000 tokens de contexto, eliminando este problema. Adicionalmente, FLAN-T5 fue entrenado principalmente en inglés y produce respuestas incoherentes ante preguntas en español. Por su parte, Groq proporciona acceso gratuito a LLaMA 3.1 mediante su API de inferencia acelerada por hardware especializado (LPU), sin costo para el volumen de consultas del proyecto.

Los parámetros de generación configurados fueron `max_tokens=600` y `temperature=0.2`. La temperatura baja (próxima a 0) hace que el modelo sea más determinista y fiel al contexto proporcionado, reduciendo la probabilidad de que genere información no respaldada por los fragmentos. Una temperatura alta produciría respuestas más creativas pero menos apropiadas para un sistema de consulta normativa donde la precisión es prioritaria.

Pipeline de recuperación y generación (RAG completo)

El pipeline de consulta opera en tres pasos encadenados, implementados en las funciones `retrieve()`, `build_prompt()` y `generate_answer()`:

Paso 1 — Recuperación. La pregunta del usuario se convierte en un embedding de 384 dimensiones usando el mismo modelo encoder, con el prefijo "query: ". FAISS compara este vector contra los 1.540 vectores del índice y retorna los K=5 fragmentos con mayor similitud coseno, junto con sus metadatos de fuente. El valor K=5 se eligió como balance entre contexto suficiente (K muy pequeño entrega información incompleta) y evitar ruido (K muy grande puede introducir fragmentos poco relevantes que confunden al generador).

Paso 2 — Construcción del prompt. Los 5 fragmentos recuperados se ensamblan en un prompt estructurado que incluye: el rol del asistente ("experto en regulación financiera colombiana"), las instrucciones de comportamiento ("responde ÚNICAMENTE con los fragmentos de contexto", "si la información no aparece, dilo explícitamente", "no inventes cifras ni normativas"), el contexto normativo recuperado con etiquetas de fuente, y la pregunta original del usuario. El diseño del prompt tiene tres objetivos: definir el tono y la especialización de la respuesta, prevenir alucinaciones al limitar el modelo al contexto dado, y garantizar trazabilidad al etiquetar cada fragmento con su documento de origen.

Paso 3 — Generación. El prompt completo se envía a LLaMA 3.1 vía la API de Groq. El modelo genera la respuesta de forma autoregresiva y retorna el texto final, que el sistema imprime junto con la lista de documentos fuente consultados.

No se implementó un *reranker* en esta versión del sistema. Un *reranker* es un modelo adicional (típicamente un *cross-encoder*) que recibe cada par (query, fragmento) de forma conjunta y produce un score de relevancia más preciso que el embedding de recuperación, al poder capturar interacciones entre ambos textos. Su ausencia constituye una oportunidad de mejora identificada: con el corpus actual de 1.540 fragmentos, los resultados de recuperación son satisfactorios, pero un *reranker* podría mejorar la precisión en consultas donde varios fragmentos tienen similitud coseno muy cercana.

4. Resultados

Preguntas de prueba y respuestas generadas:

Para evaluar el sistema se formularon cinco preguntas representativas del dominio de regulación FinTech y crowdfunding en Colombia. Las primeras cuatro corresponden a consultas que un usuario real —emprendedor, abogado o regulador— haría al sistema. La quinta es un caso de fallo intencional, diseñado para verificar que el sistema no alucina cuando la información no está en los documentos.

Pregunta 1. ¿Qué es el Espacio Controlado de Prueba (sandbox regulatorio) y cuáles son sus requisitos de admisión?

El sistema recuperó cinco fragmentos relevantes, tres provenientes del Decreto 1234 de 2020 y dos del Manual del Espacio Controlado de Prueba de la SFC. La respuesta generada fue la siguiente:

El Espacio Controlado de Prueba, también conocido como 'sandbox regulatorio', es un espacio creado por el Gobierno Nacional para promover la transformación y digitalización de la actividad financiera, bursátil y aseguradora en Colombia, manteniendo la integridad y estabilidad del sector, la debida protección del consumidor y evitando arbitrajes regulatorios. Según el Decreto 1234 de 2020, los requisitos de admisión son: (1) que el desarrollo tecnológico innovador propuesto se enmarque en alguna de las finalidades previstas en el artículo 2.35.7.1.3 del decreto; (2) que esté suficientemente avanzado para ser probado inmediatamente después de ser expedido el Certificado de Operación Temporal; y (3) que los servicios financieros vayan a ser prestados en territorio colombiano.

La respuesta es correcta y completa. No se detectaron alucinaciones; todos los elementos mencionados son trazables a los fragmentos recuperados. El sistema identificó correctamente las dos fuentes relevantes (el Decreto y el Manual) y las citó de forma diferenciada. La respuesta es útil para un usuario que necesita entender el marco general del sandbox antes de iniciar un trámite ante la SFC.

Pregunta 2. ¿Cuáles son los requisitos para que una empresa FinTech opere legalmente en Colombia?

Los cinco fragmentos recuperados provienen del Decreto 1357 de 2018, del informe de mercado LatAm Fintech 2023 y del Reporte de Inclusión Financiera 2024. La respuesta generada fue:

Según el Decreto 1357 de 2018, para que una empresa FinTech opere como sociedad de financiación colaborativa debe cumplir al menos uno de los siguientes requisitos: (a) un patrimonio igual o superior a 10.000 SMMLV; (b) ser titular de un portafolio de inversión en valores, distintos a valores de financiación colaborativa, igual o superior a 5.000 SMMLV; (c) tener la certificación de profesional del mercado como operador expedida por un organismo autorregulador; (d) tener la calidad de entidad vigilada por la Superintendencia Financiera de Colombia; o (e) ser un organismo financiero extranjero o multilateral. Adicionalmente, las sociedades deben constituirse como sociedades anónimas mediante el trámite del artículo 53 del Estatuto Orgánico del Sistema Financiero, inscribirse en el Registro Nacional de Agentes del Mercado de Valores (RNAMV) y adoptar medidas para garantizar la continuidad de los mecanismos de financiación colaborativa.

La respuesta es correcta en los puntos que cubre. Sin embargo, es parcialmente incompleta, pues el Decreto 1357 de 2018 contiene requisitos adicionales relacionados con gobierno corporativo, sistemas de administración de riesgos y requisitos tecnológicos mínimos que no aparecen en los fragmentos recuperados. Esto se debe a que dichos artículos no quedaron representados entre los cinco fragmentos top-K, lo que ilustra una limitación inherente del sistema: preguntas amplias con múltiples dimensiones normativas pueden no obtener una respuesta exhaustiva con K=5. No se detectaron alucinaciones; toda la información proviene directamente del decreto citado.

Pregunta 3. ¿Cómo se regula la protección de datos personales en los servicios financieros digitales?

Los fragmentos recuperados corresponden a la Guía de Entidades Digitales de la SFC, el Manual del Espacio Controlado de Prueba y el informe de mercado LatAm Fintech. La respuesta generada fue:

Según el Manual del Espacio Controlado de Prueba, se establece que las entidades vigiladas deben dar cumplimiento a las normas vigentes en materia de protección de datos y habeas data al adoptar tecnologías como inteligencia artificial, machine learning y big data para mejorar la prestación de servicios a los consumidores financieros. Adicionalmente, en el informe LatAm Fintech se menciona que se establecen deberes de revelación de información a las autoridades (DIAN, Banco de la

República, MINTIC, SFC y demás competentes), respetando en todo momento las leyes de protección de datos personales y cumpliendo la ley de inteligencia.

La respuesta es correcta pero incompleta desde una perspectiva jurídica. El sistema identificó correctamente que las entidades vigiladas deben cumplir con la normativa de habeas data (Ley 1581 de 2012) y las instrucciones de la SFC sobre ciberseguridad. Sin embargo, no recuperó fragmentos de la Circular Externa 007 de 2018 o la Circular 029 de 2019, que son los instrumentos normativos más específicos sobre protección de datos en el sector financiero digital. Esto se explica porque dichas circulares no forman parte del corpus documental del sistema. No hubo alucinaciones: el modelo se limitó a lo disponible en los fragmentos sin inventar normativas.

Pregunta 4. ¿Cuál es el plazo máximo de duración autorizado para el Certificado de Operación Temporal (COT) que permite a una empresa operar dentro del Espacio Controlado de Prueba?

Los cinco fragmentos recuperados provienen exclusivamente del Decreto 1234 de 2020 y del documento normativo "P1 Tit I Cap VIII — Espacio Controlado de Prueba", ambas fuentes directamente relevantes. La respuesta generada fue:

Según los fragmentos de contexto disponibles, el plazo máximo de duración autorizado para el Certificado de Operación Temporal (COT) que permite a una empresa operar dentro del Espacio Controlado de Prueba es de dos (2) años, contados desde la expedición del certificado de operación temporal.

Esta es la respuesta de mayor calidad del conjunto de evaluación. Es correcta, precisa, concisa y completamente trazable al Decreto 1234 de 2020. La pregunta es altamente específica, lo que favorece la recuperación exacta: el encoder encontró los fragmentos que contienen literalmente el dato solicitado. No se detectaron alucinaciones. La respuesta es directamente utilizable por un usuario que necesita planificar el cronograma de operación de una iniciativa dentro del sandbox.

Pregunta 5 (Caso de fallo intencional) . ¿Cuál fue el precio exacto de Bitcoin el 1 de enero de 2020?

Esta pregunta se diseñó deliberadamente para verificar el comportamiento del sistema ante una consulta cuya respuesta es imposible de encontrar en el corpus normativo. Los fragmentos recuperados corresponden a tablas financieras del Reporte de Inclusión Financiera 2024 y a artículos de la Ley 2155 de 2021, ninguno de los cuales contiene información sobre precios de criptomonedas. La respuesta generada fue:

Esta información no se encuentra en los documentos disponibles.

El comportamiento de esta respuesta es el esperado y deseado. A pesar de que FAISS recuperó cinco fragmentos —los más "ceranos" a la consulta en el espacio vectorial, aunque semánticamente distantes— el modelo generador reconoció correctamente que ninguno de ellos contenía la información solicitada y activó el mecanismo de fallback definido en el prompt. Este resultado demuestra que el diseño del prompt, con la instrucción explícita de responder "Esta información no se encuentra en los documentos disponibles" cuando el contexto no es suficiente, funciona como barrera efectiva contra las alucinaciones. Un LLM genérico sin restricción de contexto habría inventado un precio de Bitcoin con alta probabilidad.

Finalmente, el sistema no produjo alucinaciones en ninguna de las cinco consultas evaluadas. En los cuatro casos donde la información sí estaba disponible en el corpus, el modelo la recuperó y comunicó correctamente, citando en todos los casos el nombre del documento fuente. Las respuestas incompletas (preguntas 2 y 3) no se deben a generación incorrecta sino a que el corpus no contiene todos los instrumentos normativos relevantes para esas preguntas, lo que constituye una limitación del dataset y no del pipeline.

5. Limitaciones y conclusiones

Para analizar las limitaciones de nuestro proyecto, en la fase inicial de ingesta de datos, se identificó un desafío estructural asociado a la calidad de los documentos publicados por los entes reguladores. Herramientas de extracción digital como pdfplumber resultaron ineficaces ante archivos como ce015_25.pdf, el cual arrojó cero páginas procesadas debido a la ausencia de una capa de texto renderizado (al tratarse de un PDF generado a partir de una imagen escaneada). Esta restricción es especialmente crítica para el dominio financiero colombiano, donde la Superintendencia Financiera de Colombia (SFC) publica históricamente gran parte de sus circulares en formatos no estructurados que carecen de metadatos de texto. Para superar esta barrera en un entorno productivo, se requiere la integración obligatoria de un módulo de Reconocimiento Óptico de Caracteres (OCR) mediante librerías como pytesseract o servicios de nube gestionados como Amazon Textract.

Estrechamente ligado a la extracción, el procesamiento de documentos tabulares extensos —como el Reporte de Inclusión Financiera 2024 (\$20250529rif2024.pdf\$)— reveló que las estrategias de segmentación de texto (chunking) estándar destruyen la coherencia semántica de las tablas financieras. Al fragmentar estas matrices de datos en bloques planos de \$800\$ caracteres, la información numérica se descontextualiza, generando vectores dispersos que carecen de utilidad semántica en el índice vectorial FAISS. Esto se evidenció en los fallos de recuperación del sistema, donde algunos fragmentos recuperados para consultas normativas consistían únicamente en secuencias numéricas huérfanas de sus encabezados originales.

A nivel de infraestructura del generador, el diseño original del pipeline reveló la inviabilidad de implementar modelos locales de escala intermedia como FLAN-T5-Large. Dicha

inviabilidad técnica obedeció a tres factores concurrentes: en primer lugar, su restrictiva ventana de contexto de 512 tokens resultó insuficiente para procesar simultáneamente las instrucciones del sistema, la consulta del usuario y los cinco fragmentos recuperados en español, provocando desbordamientos de memoria antes de iniciar la fase de síntesis. En segundo lugar, su sesgo de entrenamiento hacia el idioma inglés deterioró la coherencia de las respuestas en español. Por último, se documentó un conflicto de dependencias en el entorno de ejecución, donde versiones de la librería transformers ≥ 4.40 producían un error silencioso al combinar parámetros estándar de muestreo como `do_sample=True` con búsquedas por haz (`num_beams=2`). La migración estratégica hacia la API de Groq, utilizando el modelo LLaMA 3.1 (\$8B), permitió resolver este cuello de botella al ofrecer una ventana de contexto de 128.000 tokens, soporte nativo para español y una latencia de generación óptima sin costo computacional local.

A pesar de la robustez del nuevo generador, la etapa de recuperación de información experimentó un trade-off intrínseco de los sistemas RAG relacionado con la exhaustividad de las respuestas. Ante consultas normativas transversales y de amplio espectro, la restricción paramétrica de recuperar un número fijo de fragmentos (establecido en $K=5$) causó respuestas fragmentadas o incompletas. Cuando una disposición legal está distribuida a lo largo de múltiples artículos y decretos que exceden los cinco fragmentos indexados más cercanos, el modelo generador carece del panorama completo para formular una síntesis exhaustiva.

Esta fragmentación del conocimiento se ve agudizada por la asimetría temporal de nuestro corpus de datos frente a la alta volatilidad del entorno regulatorio colombiano. La constante emisión de circulares externas por la SFC, resoluciones del Ministerio de Hacienda y conceptos técnicos del Banco de la República hace que un repositorio estático con corte a 2025 quede desactualizado con rapidez. La ausencia de normas fundamentales en el sector de protección de datos financieros, tales como la Circular Externa 007 de 2018 o la Circular 029 de 2019, limitó la precisión de las respuestas del modelo frente a preguntas de cumplimiento normativo digital, lo que subraya la necesidad de implementar una arquitectura de sincronización dinámica que actualice el índice de FAISS en tiempo real cada vez que un nuevo instrumento normativo sea promulgado por las autoridades nacionales.

Finalmente, para reforzar este sistema frente a la asimetría temporal de la legislación FinTech, se requiere el diseño de un pipeline de actualización incremental continuo. Mediante la automatización de web scrapers que monitoreen periódicamente los repositorios oficiales de la SFC y el Diario Oficial, los nuevos documentos normativos se descargarían de manera autónoma e incremental utilizando conectores específicos de LangChain, insertando los nuevos vectores directamente en el índice de FAISS existente sin necesidad de reconstruir la base vectorial completa. La validación científica de este sistema optimizado migraría de un análisis puramente cualitativo a un marco metodológico estandarizado apoyado en el framework Ragas. Este evaluador automatizado utilizaría un LLM como juez neutral para calcular métricas de fidelidad, relevancia de la respuesta y exhaustividad contextual, aportando un diagnóstico numérico, repetible e independiente que permita la mejora iterativa de los hiperparámetros del sistema RAG.

